

# Stock Price Prediction and Risk Estimation Using Hybrid CNN-LSTM and VaR-ECF

Alvi Yuana Febriyanti<sup>\*1</sup>, Dwi Arman Prasetya<sup>2</sup>, Trimono<sup>3</sup>

<sup>1,2,3</sup>Department of Data Science, Universitas Pembangunan Nasional ‘Veteran’ Jawa Timur, Surabaya, Indonesia.

Email: [arman.prasetya.sada@upnjatim.ac.id](mailto:arman.prasetya.sada@upnjatim.ac.id)

Received : Apr 22, 2025; Revised : May 10, 2025; Accepted : Jun 22, 2025; Published : Jun 30, 2025

## Abstract

Stock price prediction is a major challenge in the financial domain due to high volatility and complex movement patterns. Traditional methods such as fundamental and technical analysis often fail to capture the non-linear characteristics and fast-changing market dynamics, highlighting the need for more adaptive approaches. This study proposes a hybrid deep learning model, CNN-LSTM, which combines CNN's local feature extraction capabilities with LSTM's ability to model long-term temporal dependencies. To incorporate risk management, the model is also integrated with the Value at Risk (VaR) approach using the Cornish-Fisher Expansion (ECF) to estimate potential losses under extreme market conditions. The study utilizes daily historical stock price data of PT Unilever Indonesia Tbk retrieved from Yahoo Finance. Model performance is evaluated using Mean Absolute Error (MAE) and Mean Absolute Percentage Error (MAPE), where the model achieves an MAE of 78.13 and a MAPE of 2.72%, indicating relatively low absolute and relative prediction errors. These results confirm that the CNN-LSTM approach effectively models stock price movements in dynamic market environments, and the integration with VaR-ECF provides a more comprehensive risk estimate. Thus, this approach not only enhances predictive accuracy but also offers valuable decision-support tools for investors in planning investment strategies.

**Keywords :** *CNN-LSTM, Deep Learning, Expected Capital Flow (ECF), Stock Price Prediction, Value at Risk (VaR).*

This work is an open access article and licensed under a Creative Commons Attribution-Non Commercial 4.0 International License



## 1. PENDAHULUAN

Pasar saham merupakan salah satu elemen penting dalam sistem ekonomi global, di mana harga saham mencerminkan kinerja dan prospek masa depan suatu perusahaan. Oleh karena itu, memprediksi harga saham menjadi salah satu tantangan utama dalam analisis keuangan, terutama karena volatilitas yang tinggi dan ketidakpastian yang sering terjadi dalam pergerakan harga saham. Investasi saham berisiko tinggi, dan perubahan harga saham yang sangat dinamis mempengaruhi pengambilan keputusan para investor[1]. Di sisi lain, prediksi harga saham yang akurat tidak hanya membantu investor untuk meraih keuntungan tetapi juga memungkinkan pengelolaan risiko yang lebih baik dalam menghadapi fluktuasi harga yang tajam.

Berbagai metode telah dikembangkan guna memahami dan memprediksi pergerakan harga saham. Salah satunya metode tradisional seperti analisis fundamental dan teknikal yang masih banyak digunakan, namun memiliki keterbatasan yang signifikan[2]. Analisis fundamental berfokus pada nilai intrinsik saham dengan mengevaluasi faktor makroekonomi, laporan keuangan perusahaan, dan tren industri, sementara analisis teknikal mengandalkan pola harga historis dan volume perdagangan untuk memprediksi tren harga di masa depan. Namun, kedua metode ini terbatas dalam menangkap sifat non-linear dan perubahan dinamis yang terjadi pada harga saham[3].

Teknik peramalan deret waktu seperti model linier, termasuk Vector Autoregression (VAR), Bayesian Vector Autoregression (BVAR), Autoregressive Integrated Moving Average (ARIMA), dan

Generalized Autoregressive Conditional Heteroskedasticity (GARCH), telah digunakan untuk memprediksi data[4]. Model-model ini mengasumsikan kestasioneran dan hubungan linier, yang sering kali tidak sesuai dengan data keuangan karena tingginya noise, sifat non-linear, serta fluktuasi pasar yang tidak terduga[5]. Selain itu, metode statistik tradisional sering mengalami kesulitan dalam menangani ketergantungan variabel yang terus berubah, yang mengakibatkan akurasi prediksi yang lebih rendah.

Dengan perkembangan pembelajaran mesin, khususnya deep learning, para peneliti telah mengeksplorasi pendekatan alternatif untuk prediksi harga saham. Model deep learning telah menunjukkan kemampuan luar biasa dalam menangkap pola non-linear dan kompleks dalam data deret waktu[6]. Di antara model-model ini, Convolutional Neural Network (CNN) dan Long Short-Term Memory (LSTM) menjadi sangat populer karena kemampuannya dalam mengekstraksi fitur dan memodelkan ketergantungan temporal secara efektif[7].

CNN, yang awalnya dikembangkan untuk pemrosesan citra, telah diadaptasi untuk peramalan deret waktu dengan mendeteksi pola lokal dan fitur penting dalam data sekuensial[5]. Kemampuan CNN dalam mengenali hierarki spasial fitur membuatnya cocok untuk menangkap ketergantungan jangka pendek dalam pergerakan harga saham[8]. Sementara itu, LSTM, yang merupakan varian dari Recurrent Neural Network (RNN)[9], dirancang untuk mengatasi masalah vanishing gradient dalam ketergantungan jangka panjang[10], sehingga lebih efektif dalam menangkap pola harga saham dalam rentang waktu yang lebih panjang[11]. Untuk menetapkan model yang baik, perlu dilakukan prosedur tertentu dan sangat penting untuk melakukan pengujian yang tepat[12].

Sejumlah penelitian telah menyelidiki efektivitas CNN dan LSTM dalam prediksi harga saham. Misalnya, penelitian oleh Wenjie Lu et al. membandingkan metode CNN-LSTM dengan model deep learning lainnya, termasuk Multi-Layer Perceptron (MLP), RNN, CNN, dan LSTM. Hasil penelitian menunjukkan bahwa CNN-LSTM memiliki akurasi prediksi tertinggi dengan Mean Absolute Error (MAE) dan Root Mean Square Error (RMSE) terendah dibandingkan model lainnya[7]. Temuan ini menyoroti keunggulan pendekatan hybrid yang menggabungkan kemampuan ekstraksi fitur CNN dengan pemodelan temporal LSTM.

Namun demikian, sebagian besar studi yang ada lebih menekankan pada peningkatan akurasi prediktif, tanpa memperhatikan aspek penting berupa penilaian risiko kerugian, yang juga sangat krusial bagi pengambilan keputusan investasi. Hal ini menciptakan kesenjangan penelitian (research gap) yang signifikan dalam kajian prediksi harga saham. Untuk menjawab kesenjangan tersebut, penelitian ini mengusulkan pendekatan hibrida yang tidak hanya fokus pada prediksi harga, tetapi juga mengintegrasikan estimasi risiko menggunakan metode Value at Risk (VaR) dengan pendekatan Ekspansi Cornish-Fisher (ECF), guna mengukur potensi kerugian dalam kondisi pasar yang ekstrem. Dengan demikian, penelitian ini diharapkan dapat memberikan gambaran yang lebih komprehensif bagi investor, tidak hanya dalam memperkirakan harga saham di masa depan, tetapi juga dalam memahami risiko yang menyertainya.


Penelitian ini bertujuan untuk membangun model prediksi harga saham berbasis CNN-LSTM yang terintegrasi dengan metode VaR-ECF, dan mengaplikasikannya pada data historis saham PT Unilever Indonesia Tbk yang diperoleh dari Yahoo Finance. Pemilihan PT Unilever Indonesia Tbk didasarkan pada perannya yang signifikan dalam sektor konsumsi, yang merupakan salah satu indikator utama pertumbuhan ekonomi. Melalui pendekatan ini, diharapkan kontribusi nyata dapat diberikan terhadap pengembangan metode peramalan harga saham sekaligus pengelolaan risiko dalam konteks keuangan modern.

## 2. METODE

### 2.1. Theoretical Framework

#### 2.1.1 Convolutional Neural Network (CNN)

*Convolutional Neural Network* atau CNN merupakan jenis arsitektur jaringan saraf yang pertama kali diperkenalkan oleh Lecun dkk. pada tahun 1998[13]. CNN termasuk dalam kategori *feedforward neural network* yang dikenal memiliki kinerja baik dalam pengolahan citra serta emrosesan bahasa alami. Meskipun pada awalnya CNN lebih banyak digunakan untuk data visual, penerapan CNN telah berkembang dan terbukti efektif digunakan dalam pemodelan data deret waktu [13]. Salah satu keunggulan CNN adalah penerapan konsep persepsi *local perception* dan *weight sharing*, yang secara signifikan membantu mengurangi jumlah parameter pada model. Secara umum, arsitektur CNN terdiri dari dua lapisan utama, yaitu lapisan konvolusi (*convolutional layer*) untuk ekstraksi fitur dan lapisan penyatuan (*pooling layer*) yang berfungsi mereduksi dimensi data.




Gambar 1. Ilustrasi Struktur CNN pada Pengenalan Citra

Gambar 1 memperlihatkan struktur umum CNN yang sering digunakan dalam pengenalan gambar. Setelah proses konvolusi, fitur-fitur penting akan diekstraksi dari data, yang umumnya menyebabkan peningkatan dimensi fitur[14]. Untuk mengatasi permasalahan ini, ditambahkan lapisan penyatuan yang bertujuan untuk mengurangi jumlah fitur dan beban komputasi saat pelatihan. CNN terinspirasi dari proses biologis, di mana pola konektivitas antar neuron menyerupai organisasi neuron pada korteks visual makhluk hidup. Jika dibandingkan dengan algoritma klasifikasi gambar lainnya, CNN memiliki keunggulan berupa kebutuhan proses prapengolahan data yang lebih sederhana dan efisien.

#### 2.1.2 Long Short-Term Memory (LSTM)

*Long Short-Term Memory* (LSTM) merupakan pengembangan dari *Recurrent Neural Network* (RNN) yang dirancang untuk mengatasi permasalahan hilangnya nilai gradien yang sering terjadi pada RNN[15]. LSTM digunakan untuk menangani masalah gradien yang menghilang, di mana gradien cenderung menjadi nol atau mendekati nol, dengan menggunakan mekanisme pintu (*gate*)[16]. Algoritma LSTM menggabungkan informasi dari keadaan sebelumnya, memori saat ini, dan nilai masukan. Dengan cara ini, LSTM mampu menangkap ketergantungan jangka panjang dengan efisien[17].



Gambar 2. Arsitektur LSTM

Gambar 2 memperlihatkan arsitektur umum LSTM, di mana setiap gerbang berperan penting dalam mengatur aliran informasi. Input gate menentukan seberapa besar informasi baru yang diterima,

sementara forget gate berfungsi menyaring informasi yang sudah tidak relevan. Cell state berperan sebagai memori jangka panjang, dan output gate menentukan informasi yang diteruskan sebagai hasil keluaran. Kombinasi mekanisme ini memungkinkan LSTM menghasilkan prediksi yang akurat untuk data sekuensial dengan ketergantungan jangka panjang.

$$z^{(t)} = g(W_z x^{(t)} + R_z y^{(t-1)} + b_z) \quad (1)$$

Persamaan (1) ini digunakan untuk memperbarui komponen input blok, dengan mengombinasikan input saat ini  $x^{(t)}$  dan output dari LSTM pada iterasi sebelumnya  $y^{(t-1)}$ . Bobot  $W_z$  dan  $R_z$  masing-masing berkaitan dengan input dan output, sedangkan  $b_z$  adalah bias vektor[18].

$$i^{(t)} = \sigma(W_i x^{(t)} + R_i y^{(t-1)} + p_i \odot c^{(t-1)} + b_i) \quad (2)$$

Persamaan (2) menghitung nilai input gate, yang menentukan seberapa besar informasi baru dari input  $x^{(t)}$ , output sebelumnya  $y^{(t-1)}$  dan *cell value*  $c^{(t-1)}$  yang akan diteruskan. Parameter  $\odot$  menunjukkan perkalian elemen vektor, sedangkan  $W_i$ ,  $R_i$  dan  $p_i$  adalah bobot-bobot yang terkait. Nilai  $i^{(t)}$  menentukan seberapa banyak informasi baru akan dimasukkan ke cell state.

$$f^{(t)} = \sigma(W_f x^{(t)} + R_f y^{(t-1)} + p_f \odot c^{(t-1)} + b_f) \quad (3)$$

Persamaan (3) menghitung forget gate yang berfungsi untuk menentukan informasi mana dari cell state sebelumnya  $c^{(t-1)}$ . Yang harus dilupakan. Nilai  $f^{(t)}$  menjadi kunci untuk mengendalikan pembersihan memori yang sudah tidak relevan.

$$c^{(t)} = z^{(t)} \odot i^{(t)} + c^{(t-1)} \odot f^{(t)} \quad (4)$$

Persamaan (4) memperbarui nilai cell state dengan mempertimbangkan informasi baru dari input block dan informasi lama yang dipertahankan oleh forget gate.

$$o^{(t)} = \sigma(W_o x^{(t)} + R_o y^{(t-1)} + p_o \odot c^{(t)} + b_o) \quad (5)$$


Perhitungan output gate pada persamaan (5) menentukan informasi mana yang akan diteruskan ke output  $y^{(t)}$ , berdasarkan input saat ini, output sebelumnya, dan cell state terbaru.

$$y^{(t)} = g(c^{(t)}) \odot o^{(t)} \quad (6)$$

Pada Persamaan (6) nilai output dihitung dengan mengalikan cell state saat ini dengan hasil dari output gate. Fungsi aktivasi  $\sigma$ ,  $g$ , dan  $h$  merupakan fungsi nonlinear yang biasa digunakan, di mana hiperbolik tangen  $\tanh$  umum diterapkan untuk *input block* dan output *activation function*[19].

### 2.1.3 CNN-LSTM

CNN dan LSTM dapat dikombinasikan untuk membangun model *deep learning* yang mampu mempelajari pola-pola kompleks dan tersembunyi dari kumpulan data berskala besar dan beragam, termasuk data deret waktu, khususnya di sektor keuangan [7]. Integrasi kedua model ini bertujuan untuk meningkatkan ketepatan prediksi, seperti pada pergerakan indeks harga saham. CNN berfokus pada identifikasi fitur yang tampak dominan dalam data, sehingga sering dimanfaatkan dalam proses rekayasa fitur. Sementara itu, LSTM dirancang untuk memproses data berurutan dan banyak digunakan dalam analisis deret waktu [20]. Dengan konsep hybrid ini diharapkan solusi yang diberikan akan menjadi lebih baik serta komprehensif karena tiap-tiap model memiliki peran dan kemampuan yang berbeda untuk dapat menangkap pola yang tersembunyi dalam data.



Gambar 3. Arsitektur CNN-LSTM

Gambar 3 merupakan arsitektur dari metode hybrid CNN-LSTM. Dua jenis metode ini masing – masing memiliki keunggulan dalam menangani data tertentu[21]. Pada bagian awal, lapisan input menerima data mentah yang dapat berupa deret waktu atau data berstruktur grid, seperti gambar. Data ini kemudian diproses oleh lapisan konvolusi (*convolution layer*) dalam CNN, di mana filter-filter digunakan untuk mengekstraksi fitur-fitur penting dari data tersebut. Setelah melalui lapisan konvolusi, hasilnya dilanjutkan ke lapisan pooling yang berfungsi untuk mengurangi dimensi data, sehingga mengurangi kompleksitas dan menjaga informasi penting[7].

Selanjutnya, fitur-fitur yang telah diekstraksi oleh CNN diteruskan ke lapisan LSTM, yang dirancang khusus untuk menangani data sekuensial dengan mempertimbangkan urutan waktu. LSTM memiliki kemampuan untuk mengingat informasi dari masa lalu yang relevan, sehingga mampu membuat prediksi atau keputusan yang lebih akurat berdasarkan data urutan [22]. Akhirnya, hasil dari lapisan LSTM diteruskan ke lapisan output, yang menghasilkan prediksi akhir atau keluaran yang diinginkan. Kombinasi CNN dan LSTM dalam arsitektur ini memungkinkan model untuk menangkap pola kompleks dalam data dan memprosesnya secara efisien [23], sehingga sangat cocok untuk tugas-tugas seperti prediksi harga saham atau analisis deret waktu lainnya.

#### 2.1.4 Value at Risk (VaR)

*Value at Risk* (VaR) merupakan salah satu metode statistik yang digunakan untuk mengukur risiko kerugian maksimum yang berpotensi terjadi pada sebuah portofolio investasi dalam jangka waktu tertentu dengan tingkat kepercayaan yang telah ditetapkan [24]. Konsep VaR menjelaskan seberapa besar fluktuasi nilai investasi atau portofolio yang mungkin terjadi dalam periode tertentu pada tingkat keyakinan tertentu [25]. Prinsip dasar dari VaR adalah pengakuan bahwa setiap investasi pasti mengandung risiko, sehingga penting bagi investor dan manajer risiko untuk memahami potensi besarnya kerugian yang mungkin timbul [26]. Misalkan  $\iota$  adalah nilai VaR dari suatu portofolio pada tingkat kepercayaan  $\alpha \in (0,1)$  sehingga probabilitas kerugian  $L$  melebihi  $\iota$ , tidak lebih dari  $(1 - \alpha)$  [1]. Secara sistematis VaR dirumuskan sebagai :

$$\text{VaR}_{\alpha} = \inf\{l \in R: F_L(l) \geq \alpha\} \quad (7)$$

Dengan keterangan :

$\alpha$  : tingkat kepercayaan

$F_L(l)$  : fungsi distribusi kumulatif dari  $L$ .

#### 2.1.5 Ekspansi Cornish-Fisher (ECF)

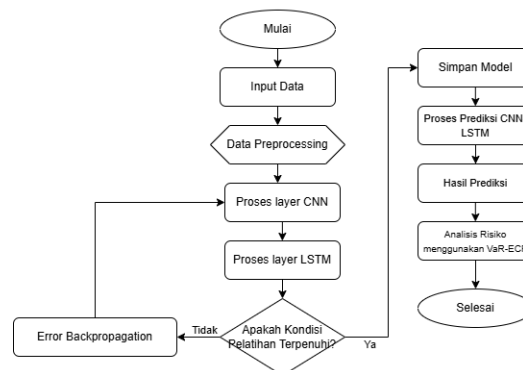
*Ekspansi Cornish-Fisher* atau ECF adalah metode statistik yang digunakan dalam analisis risiko keuangan untuk mengoreksi asumsi distribusi normal dalam pengukuran risiko. Metode ini

memperhitungkan non-normalitas dalam distribusi aset atau portofolio dengan mempertimbangkan skewness (ketidak simetrisan) dan kurtosis (ekor berat) dalam distribusi tersebut [27]. Skewness adalah sebuah metrik yang mengukur tingkat asimetri dari distribusi data. Kurtosis adalah sebuah ukuran yang menggambarkan sejauh mana puncak kurva distribusi melebar atau meruncing. Kurva distribusi dapat memiliki berbagai tingkat 16 keruncingan [28].

Parameter VaR digunakan untuk mengukur sejauh mana distribusi berbeda dari distribusi Normal yang memiliki skewness 0 dan kurtosis 3. Jika return saham tidak mengikuti distribusi Normal sempurna, yang ditandai oleh adanya perbedaan dalam skewness dan kurtosis, maka penting untuk mempertimbangkan kedua faktor ini agar perhitungan VaR menjadi lebih efisien [27]. Oleh karena itu, metode Ekspansi Cornish-Fisher digunakan untuk menghasilkan bentuk kuantil- $\alpha$  yang diperluas. Jika kurtosis memiliki nilai kurang dari 3, maka formula ECF dapat dinyatakan sebagai berikut :

$$ECF = q_{\alpha} + \frac{((q_{\alpha})^2 - 1)S(X)}{6} + \frac{((q_{\alpha})^3 - 3q_{\alpha})K(X)}{24} - \frac{(2(q_{\alpha})^3 - 5q_{\alpha})S^2(X)}{36} \quad (8)$$

## 2.2. Research Methodology



Gambar 4. Flowchart

Desain penelitian pada Gambar 4 dikembangkan dengan tujuan untuk memberikan panduan dan target yang jelas untuk studi[12]. Agar permasalahan yang dieksplorasi dalam penelitian ini dapat dijawab dan dijelaskan secara melalui metode yang jelas dan dapat dipertanggungjawabkan [29], maka artikel ini disusun sebagai berikut :

### 2.2.1 Pengumpulan Data

Penelitian ini menggunakan data historis harga saham harian PT Unilever Indonesia Tbk yang diperoleh dari platform Yahoo Finance, dengan rentang waktu dari 1 Januari 2019 hingga 31 Mei 2024. Rentang ini dipilih karena mencerminkan siklus ekonomi yang luas dan fluktuasi pasar yang relevan. PT Unilever Indonesia Tbk dipilih karena mewakili saham blue-chip di Indonesia, dengan karakteristik likuiditas tinggi, kapitalisasi pasar besar, dan frekuensi perdagangan yang aktif.

Atribut utama yang digunakan meliputi harga pembukaan, harga tertinggi, harga terendah, harga penutupan, serta volume perdagangan. Informasi ini digunakan untuk mendukung proses prediksi dan perhitungan risiko secara lebih akurat.

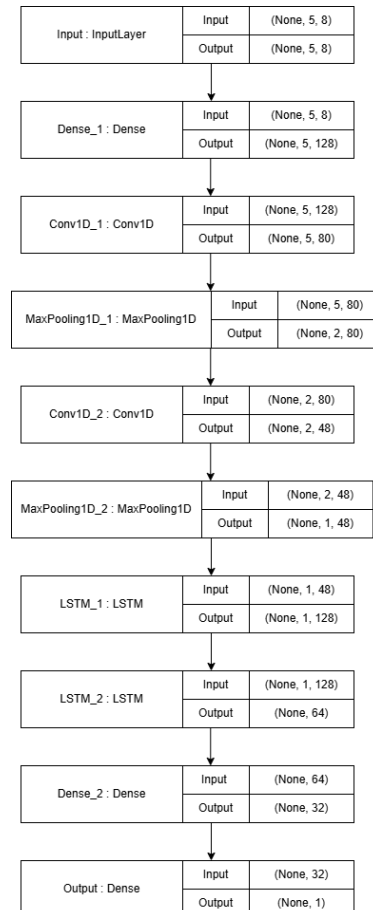
### 2.2.2 Pra-pemrosesan Data

Pada tahap ini, data dibersihkan dan diubah agar siap digunakan untuk pelatihan model. Proses ini mencakup penanganan nilai yang hilang, deteksi outlier, normalisasi data, pengorganisasian data ke dalam format yang dapat diproses oleh model CNN-LSTM, serta pembagian data ke dalam data pelatihan dan pengujian dengan rasio 80:20. Preprocessing yang tepat akan meningkatkan performa model.



### 2.2.3 Pengembangan Model CNN-LSTM

Langkah ini fokus pada pembangunan model hybrid CNN-LSTM. CNN digunakan untuk mengekstrak fitur penting dari data, sedangkan LSTM menangani ketergantungan temporal, yang penting untuk memahami pola pergerakan harga saham secara berurutan.



Gambar 5. Struktur Model CNN-LSTM

Struktur model CNN-LSTM yang terdapat pada Gambar 5 terdiri dari beberapa tahap pemrosesan berurutan. Data masukan terlebih dahulu melewati layer Dense untuk pembentukan representasi awal, lalu diproses oleh dua layer Conv1D dan MaxPooling1D untuk mengekstrak fitur spasial penting. Setelah proses ekstraksi fitur, data dialirkan ke dua layer LSTM yang berfungsi menangkap pola urutan dan ketergantungan temporal dalam data saham. Output dari LSTM kemudian diteruskan ke layer Dense untuk menghasilkan prediksi akhir. Kombinasi arsitektur ini memungkinkan model memahami baik fitur lokal maupun pola sekuensial dalam pergerakan harga saham.

### 2.2.4 Perhitungan VaR-ECF

Setelah prediksi harga saham diperoleh, return saham dihitung. Berdasarkan distribusi return, dilakukan estimasi risiko menggunakan metode VaR dengan pendekatan Cornish-Fisher Expansion. Rumus ECF memperhitungkan skewness dan kurtosis untuk menghitung kuantil modifikasi. Nilai VaR dihitung untuk tingkat kepercayaan 95% dan 99%. Rumus matematis ECF digunakan sesuai standar distribusi tidak normal seperti pada rumus (8).

### 2.2.5 Evaluasi Model

Evaluasi dilakukan dengan menghitung Mean Absolute Error (MAE) dan Mean Absolute Percentage Error (MAPE) antara nilai prediksi dan aktual. Selain itu, hasil perhitungan VaR-ECF dibandingkan dengan distribusi aktual return saham untuk mengukur akurasi estimasi risiko. Model dianggap efektif jika memiliki MAE dan MAPE rendah serta estimasi VaR yang mencerminkan risiko pasar secara realistis..

### 3. HASIL

#### 3.1. Pengumpulan Data

PT Unilever Indonesia Tbk, sebuah perusahaan terkemuka di sektor barang konsumen, dipilih untuk penelitian ini karena peranannya yang signifikan dalam perekonomian Indonesia, kapitalisasi pasar yang besar, dan likuiditas yang tinggi. Unilever Indonesia juga dikenal dengan frekuensi perdagangan yang aktif, menjadikannya representasi yang kuat dari saham blue-chip di pasar Indonesia.

Tabel 1. Data PT Unilever Tbk

Date	Open	High	Low	Last	Close	Adj Close	Volume
1/1/2019	1266.95	1267.9	1260.00	1262.30	1264.15	254790	3220.75
1/2/2019	1267.00	1272.4	1255.55	1262.95	1263.30	940123	11885.37
1/3/2019	1265.00	1284.0	1259.95	1282.90	1280.60	1317565	16821.01
1/4/2019	1285.00	1301.0	1280.90	1299.00	1299.20	2614380	33794.17
1/7/2019	1300.00	1304.0	1290.25	1295.00	1294.85	910376	11799.61

Dalam tabel 1 dapat dilihat data yang digunakan dalam penelitian ini mencakup periode 1 Januari 2019 hingga 31 Mei 2024, yang dipilih untuk mencakup siklus ekonomi yang luas dan untuk menangkap fluktuasi pasar yang relevan dalam jangka waktu yang cukup panjang. Pemilihan periode ini juga didasari oleh berbagai peristiwa pasar yang dapat memberikan gambaran yang lebih komprehensif mengenai dinamika harga saham Unilever Indonesia.



Gambar 6. Daily Close PT Unilever Tbk

Grafik harga penutupan saham PT Unilever Indonesia Tbk pada Gambar 6 menunjukkan tren kenaikan yang signifikan dari 1.500 hingga lebih dari 3.000 selama periode 2019 hingga 2024, mencerminkan pertumbuhan yang stabil meskipun terdapat fluktuasi harga yang tajam. Pergerakan harga yang tidak rata ini mencerminkan volatilitas pasar, yang dapat dipengaruhi oleh faktor ekonomi global, kebijakan perusahaan, atau perubahan makroekonomi. Lonjakan tajam di akhir grafik menunjukkan adanya peristiwa pasar atau perubahan penting yang berdampak pada harga saham Unilever. Grafik ini memberikan gambaran yang jelas tentang dinamika harga saham dalam periode waktu tertentu.

#### 3.2. Pra-pemrosesan Data

Pada tahap pemrosesan data, dilakukan pembersihan dan konversi data untuk menangani nilai yang hilang dan duplikasi, memastikan data yang digunakan bersih dan akurat. Selanjutnya, dilakukan



normalisasi untuk menskalakan data agar konsisten dan siap untuk digunakan dalam pelatihan model. Terakhir, data dibagi menjadi subset pelatihan dan pengujian guna memastikan model dapat melakukan generalisasi dengan baik, menghindari overfitting, dan meningkatkan akurasi prediksi.

Tabel 2. Output Normalisasi Data

	Open	High	Low	Close
<b>0</b>	0.126695	0.12679	0.126000	0.126415
<b>1</b>	0.126700	0.12724	0.125555	0.126330
<b>2</b>	0.126500	0.12840	0.125995	0.128060
<b>3</b>	0.128500	0.13010	0.128090	0.129920
<b>4</b>	0.130000	0.13040	0.129025	0.129485
...	...	...	...	...
<b>1326</b>	0.345700	0.347100	0.341080	0.343355
<b>1327</b>	0.345000	0.349580	0.343370	0.348240
<b>1328</b>	0.347995	0.350900	0.347525	0.349390
<b>1329</b>	0.351295	0.353315	0.347600	0.349180
<b>1330</b>	0.348080	0.351770	0.345800	0.350205

Tabel 2 merupakan output dari normalisasi data, output menunjukkan bahwa setelah normalisasi, nilai pada kolom-kolom tersebut berkurang signifikan, seperti nilai awal 1266,95 menjadi 0,126695. Hasil ini memastikan bahwa dataset telah disesuaikan untuk model analitik atau pembelajaran mesin, dengan meminimalkan potensi masalah skala yang bisa mengganggu model prediktif.

Tabel 3. Output Pembagian Data

<b>x_train</b>	(1060, 5, 4)
<b>y_train</b>	(1060,)
<b>x_test</b>	(265, 5, 4)
<b>y_test</b>	(265,)

Tabel 3 merupakan output dari pembagian data dan reshaping data. Pembagian dilakukan untuk memisahkan data pelatihan (80%) dan pengujian (20%). Setelah itu, data di reshaped ke dalam dimensi yang sesuai (samples, timesteps, features) untuk memastikan model dapat memproses data berurutan. Output menunjukkan dimensi data pelatihan (x\_train: (1000, 5, 4)) dan data pengujian (x\_test: (265, 5, 4)), yang siap digunakan dalam model machine learning.

### 3.3. Pengembangan Model CNN-LSTM

Model CNN-LSTM dibangun dengan arsitektur berlapis yang menggabungkan Conv1D dan LSTM untuk menangkap pola lokal dan ketergantungan temporal dalam data saham. Lapisan Conv1D digunakan untuk mengekstraksi fitur lokal dari data berurutan, sementara LSTM membantu model untuk memahami hubungan jangka panjang antar langkah waktu dalam data.

Tabel 4. Struktur Model CNN-LSTM

Layer (type)	Output Shape	Param #
<b>dense_39 (Dense)</b>	(None, 5, 128)	640
<b>conv1d_26</b>	(None, 5, 80)	10,320
<b>max_pooling1d_26 (MaxPooling1D)</b>	(None, 2, 80)	0


<b>conv1d_27 (Conv1D)</b>	(None, 2, 48)	3,888
<b>max_pooling1d_27 (MaxPooling1D)</b>	(None, 1, 48)	0
<b>lstm_26 (LSTM)</b>	(None, 1, 128)	90,624
<b>lstm_27 (LSTM)</b>	(None, 64)	49,408
<b>dense_40 (Dense)</b>	(None, 32)	2,080
<b>dense_41 (Dense)</b>	(None, 1)	33

Output yang ditampilkan pada Tabel 4 menggambarkan struktur arsitektur model CNN-LSTM yang memiliki 156.993 parameter yang dapat dilatih (trainable) dan ukuran model sebesar 613.25 KB. Lapisan pertama, yaitu Dense, menerima input dari data dengan 5 fitur dan menghasilkan 128 unit output, membutuhkan 640 parameter. Dilanjutkan dengan lapisan Conv1D dengan 80 filter, yang dilengkapi dengan MaxPooling1D, menghasilkan output berukuran (None, 2, 80). Lapisan Conv1D kedua melanjutkan ekstraksi fitur lebih lanjut dengan 48 filter, yang dikombinasikan dengan lapisan MaxPooling1D untuk mengurangi dimensi menjadi (None, 1, 48). Proses ini memberikan dasar bagi model untuk mempelajari pola spasial dalam data berurutan.

Selanjutnya, lapisan LSTM pertama dengan 128 unit menangkap ketergantungan temporal pada data, diikuti oleh LSTM kedua dengan 64 unit untuk lebih mengoptimalkan pemahaman terhadap urutan jangka panjang dalam data sekuensial. Terakhir, dua lapisan Dense digunakan untuk menghasilkan prediksi akhir dengan 32 unit, dan output dari model berukuran 1, yang berfungsi sebagai nilai prediksi untuk masalah regresi atau klasifikasi biner. Total parameter pada model ini adalah hasil dari kombinasi parameter yang ada di setiap lapisan, dengan lapisan LSTM menyumbang sebagian besar parameter, menunjukkan kapasitas besar model untuk menangkap hubungan kompleks dalam data waktu.

### 3.4. Prediksi CNN-LSTM

Setelah model CNN-LSTM dibangun dan dilatih dengan data historis saham PT Unilever Indonesia Tbk, model digunakan untuk memprediksi harga saham di masa depan. Proses prediksi dilakukan dengan memasukkan data validasi yang tidak digunakan selama pelatihan untuk mengevaluasi kemampuan model dalam memprediksi harga saham yang belum terlihat. Hasil prediksi kemudian dievaluasi menggunakan metrik Mean Absolute Error (MAE) dan Root Mean Square Error (RMSE) untuk mengukur akurasi prediksi.



Gambar 7. Hasil Prediksi CNN-LSTM

Secara keseluruhan, dapat diamati pada Gambar 7 bahwa model ini berhasil memodelkan tren pergerakan harga saham dengan baik, baik pada data pelatihan maupun data validasi. Prediksi harga saham pada kedua subset ini menunjukkan pola yang sangat mirip dengan harga saham yang sebenarnya ( $y_{train}$ ), yang mengindikasikan kemampuan model untuk menangkap pola jangka pendek pergerakan harga dengan cukup akurat.

Namun, meskipun terdapat kesesuaian yang cukup baik antara prediksi dan data aktual, sedikit perbedaan terlihat pada beberapa titik data. Perbedaan ini bisa disebabkan oleh variasi dalam pergerakan harga saham yang lebih tidak terduga atau oleh model yang mungkin belum sepenuhnya optimal dalam menangani fluktuasi ekstrem dalam data saham yang lebih volatile. Meskipun demikian, hasil ini menegaskan bahwa model CNN-LSTM memiliki kemampuan yang baik dalam memprediksi harga saham di kedua subset, dengan tingkat kesalahan yang relatif rendah pada data pelatihan dan validasi, menunjukkan potensi model ini untuk digunakan dalam prediksi harga saham secara praktis dalam konteks pasar yang dinamis.



Gambar 8. Hasil Prediksi pada Tiga Subset Data Berbeda

Untuk tiga subset data berbeda yang dicantumkan dalam Gambar 8 adalah data pelatihan, validasi, dan pengujian. Perbandingan visual ini menunjukkan kemampuan model dalam menangkap tren pergerakan harga seiring waktu, yang menunjukkan efektivitas model dalam memodelkan perilaku dinamis harga saham. Prediksi harga dari model ini secara umum mengikuti tren harga aktual dengan hanya sedikit penyimpangan, terutama pada periode yang lebih volatil dalam data.

Meskipun model menunjukkan kinerja yang baik di seluruh subset, gambar ini juga memperlihatkan sedikit perbedaan antara prediksi dan nilai aktual, khususnya pada beberapa titik dengan volatilitas tinggi. Perbedaan ini dapat dijelaskan oleh kesulitan dalam memprediksi harga saham selama fluktuasi ekstrim. Namun, secara keseluruhan, kesesuaian antara prediksi dan nilai aktual menunjukkan bahwa model ini memiliki kekuatan prediksi yang kuat. Tingkat kesalahan yang relatif rendah di seluruh subset lebih mengukuhkan potensi model ini untuk digunakan dalam prediksi harga saham secara praktis, menunjukkan aplikabilitasnya dalam peramalan keuangan dunia nyata dan pengambilan keputusan di pasar yang volatil.

Tabel 5. Model Performance

Mean Absolute Error	Mean Absolute Percentage Error
78.129038731	2.720946305

Model performance pada Tabel 5 menghasilkan MAE sebesar 78,13 menunjukkan bahwa rata-rata selisih absolut antara nilai prediksi dan nilai aktual adalah sekitar 78,13, yang mengindikasikan tingkat kesalahan yang cukup besar namun masih dalam batas yang dapat diterima. Sementara itu, nilai MAPE yang tercatat sebesar 2,72% menggambarkan bahwa prediksi model secara keseluruhan memiliki kesalahan rata-rata sebesar 2,72% dari nilai aktual, yang menunjukkan akurasi yang relatif tinggi dalam konteks prediksi harga saham. Metrik ini mencerminkan bahwa meskipun terdapat beberapa ketidaksesuaian antara prediksi dan nilai aktual, model mampu memberikan prediksi yang cukup akurat dengan kesalahan relatif yang rendah. Hal ini menunjukkan efektivitas model dalam menangani data saham yang volatil dan kompleks.

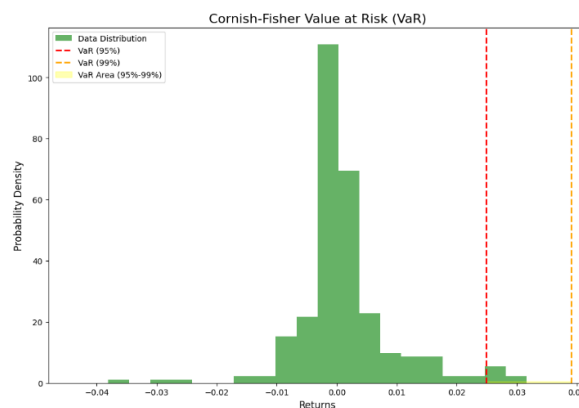
### 3.5. Risiko Kerugian Menggunakan VaR-ECF

Hasil prediksi dari model CNN-LSTM, yang mencakup nilai aktual dan prediksi harga saham, digunakan untuk menghitung *Value at Risk* (VaR) dengan pendekatan *Ekspansi Cornish-Fisher* (ECF). Untuk menangani outlier metode ini menggunakan winsorization untuk memastikan data berada dalam percentil yang wajar. Metode Cornish-Fisher digunakan untuk mengoreksi distribusi data berdasarkan nilai skewness dan kurtosis, yang membantu mengatasi ketidaknormalan distribusi data.

Tabel 6. Output Perhitungan VaR

<b>VaR (Cornish-Fisher Expansion) at 95% confidence level :</b>	0.0249
<b>VaR (Cornish-Fisher Expansion) at 99% confidence level :</b>	0.0390

Hasil perhitungan VaR pada tingkat kepercayaan 95% dan 99% pada Tabel 6 menunjukkan estimasi potensi kerugian yang dapat dihadapi oleh investor dalam periode waktu tertentu. Nilai VaR sebesar 0.0249 pada tingkat keyakinan 95% menunjukkan bahwa dalam kondisi pasar normal, kemungkinan kerugian melebihi 2.49% hanya sebesar 5%. Sementara pada tingkat kepercayaan 99%, VaR tercatat 0.0390, yang berarti kemungkinan kerugian melebihi 3.90% adalah sebesar 1%. Bagi investor, informasi ini penting untuk mengantisipasi potensi kerugian ekstrem dan menyesuaikan strategi investasi sesuai toleransi risiko. Estimasi VaR ini memberikan batas bawah kerugian yang realistis dan dapat digunakan sebagai dasar kebijakan manajemen risiko.



Gambar 8. Visualisasi Risiko Kerugian VaR-ECF

Dalam gambar 8, distribusi data menunjukkan pola pengembalian saham yang diprediksi, dengan garis vertikal merah yang mewakili VaR pada tingkat kepercayaan 95% dan garis vertikal oranye yang mewakili VaR pada tingkat kepercayaan 99%. Area yang ditandai oleh garis-garis tersebut menggambarkan risiko kerugian yang dapat diprediksi, yang memungkinkan investor untuk mengantisipasi potensi kerugian yang lebih besar pada tingkat kepercayaan yang lebih tinggi. Grafik ini memberikan wawasan yang lebih dalam tentang risiko pasar dan dapat digunakan untuk strategi manajemen risiko yang lebih efektif dalam pengambilan keputusan investasi saham.

## 4. DISKUSI

Penelitian ini menunjukkan bahwa model hybrid CNN-LSTM mampu memberikan hasil prediksi harga saham yang kompetitif dengan tingkat akurasi yang tinggi. Dengan MAE sebesar 78,13 dan MAPE sebesar 2,72%, model ini membuktikan kemampuannya dalam menangkap pola kompleks dalam data harga saham. Hasil ini konsisten dengan temuan Wenjie Lu dkk. [6], yang menyatakan bahwa

CNN-LSTM unggul dibandingkan arsitektur lain seperti MLP, RNN, dan CNN tunggal dalam hal akurasi prediksi. Studi lain oleh Faza Inaku dkk [20] juga menyoroti efektivitas LSTM dalam menangani data keuangan yang bersifat sekuensial dan non-linear, meskipun tidak mengombinasikannya dengan CNN. Dalam konteks prediksi harga saham berbasis deep learning, penggabungan CNN dan LSTM memberikan keunggulan ganda: CNN menangkap fitur lokal yang relevan, sementara LSTM memahami ketergantungan temporal, yang terbukti meningkatkan kinerja prediksi dalam studi ini.

Selain prediksi, penelitian ini juga memberikan kontribusi signifikan dalam aspek pengukuran risiko dengan mengintegrasikan Value at Risk (VaR) menggunakan pendekatan Cornish-Fisher Expansion (ECF). Hasil perhitungan menunjukkan bahwa pada tingkat kepercayaan 95%, potensi kerugian maksimum yang dapat terjadi adalah sebesar 2,49%, sedangkan pada tingkat kepercayaan 99%, potensi kerugian meningkat menjadi 3,90%. Nilai-nilai ini memberikan estimasi risiko kerugian ekstrem yang realistis dengan mempertimbangkan distribusi yang tidak normal melalui parameter skewness dan kurtosis. Pendekatan ini terbukti efektif dalam memperbaiki estimasi risiko dibandingkan dengan metode VaR konvensional yang mengasumsikan distribusi normal. Dengan demikian, integrasi VaR-ECF dalam model prediktif memungkinkan investor untuk tidak hanya melihat potensi keuntungan, tetapi juga mengukur dan mengantisipasi kerugian dengan cara yang lebih informatif dan realistis.

Dari sisi praktis, hasil penelitian ini memberikan panduan strategis bagi investor dalam pengambilan keputusan. Model CNN-LSTM yang diintegrasikan dengan VaR-ECF tidak hanya memberikan prediksi harga saham yang akurat, tetapi juga menawarkan kerangka kerja manajemen risiko yang kuat. Investor dapat menggunakan informasi VaR untuk menentukan toleransi risiko dan menetapkan batas kerugian yang dapat diterima dalam perencanaan portofolio. Selain itu, visualisasi risiko yang ditunjukkan dalam grafik VaR-ECF memberikan pemahaman intuitif tentang potensi kerugian, yang dapat dijadikan dasar dalam merancang strategi lindung nilai (hedging) atau diversifikasi investasi.

Namun, penelitian ini juga memiliki beberapa keterbatasan. Pertama, studi hanya menggunakan data dari satu perusahaan, yaitu PT Unilever Indonesia Tbk. Meskipun pemilihan ini didasarkan pada stabilitas dan representatifnya saham dalam indeks blue-chip, generalisasi model ke saham lain dengan karakteristik volatilitas berbeda masih perlu diuji. Kedua, penelitian ini belum membandingkan arsitektur CNN-LSTM dengan model-model deep learning terbaru seperti Transformer atau Temporal Fusion Transformer (TFT), yang telah menunjukkan performa unggul dalam beberapa studi keuangan terkini. Untuk itu, arah penelitian selanjutnya dapat mencakup penerapan model ke berbagai saham dari sektor berbeda, serta eksplorasi arsitektur model yang lebih kompleks atau menggunakan ensemble learning untuk meningkatkan akurasi dan robustness model prediksi.

## 5. KESIMPULAN

Penelitian ini menyajikan model hybrid CNN-LSTM yang terbukti mampu memprediksi harga saham PT Unilever Indonesia Tbk dengan akurasi yang tinggi, sebagaimana dibuktikan oleh nilai MAE sebesar 78,13 dan MAPE sebesar 2,72%. Model ini berhasil menangkap pola pergerakan harga saham yang kompleks dan non-linear secara efektif. Selain itu, integrasi metode Value at Risk (VaR) menggunakan pendekatan Cornish-Fisher Expansion (ECF) memperkuat kemampuan model dalam mengestimasi risiko kerugian, dengan hasil perhitungan yang realistis pada tingkat kepercayaan 95% dan 99%. Temuan ini menegaskan bahwa kombinasi CNN-LSTM dan VaR-ECF tidak hanya akurat dalam prediksi harga, tetapi juga andal dalam pengukuran risiko pasar.

Secara praktis, pendekatan ini dapat digunakan sebagai alat bantu yang informatif bagi investor dalam merancang strategi investasi dan mengelola risiko dengan lebih terukur. Estimasi risiko yang diperoleh dari VaR-ECF memberikan batasan kerugian potensial yang dapat diantisipasi, sehingga meningkatkan kualitas pengambilan keputusan di lingkungan pasar yang penuh ketidakpastian. Untuk

pengembangan selanjutnya, disarankan untuk menerapkan model ini pada saham dari berbagai sektor industri guna menguji generalisasi dan kestabilan model. Selain itu, eksplorasi terhadap arsitektur hybrid lainnya, seperti Transformer-LSTM atau penggunaan model ensemble, serta integrasi dengan teknik penilaian risiko lanjutan seperti Conditional VaR (CVaR) atau Monte Carlo Simulation, dapat menjadi arah penelitian yang menjanjikan untuk meningkatkan presisi dan daya guna model dalam dunia nyata.

## DAFTAR PUSTAKA

- [1] F. Seru, "ANALISIS RISIKO VAR DAN CVAR PADA HASIL PREDIKSI HARGA SAHAM PT. ASTRA INTERNATIONAL TBK," Bulan Juni, 2023. [Online]. Available: <http://journal.umpo.ac.id/index.php/silogisme>
- [2] D. I. Asih Maruddani and D. Ispriyanti, "PEMODELAN HARGA SAHAM DENGAN GEOMETRIC BROWNIAN MOTION DAN VALUE AT RISK PT CIPUTRA DEVELOPMENT Tbk," *JURNAL GAUSSIAN*, vol. 6, no. 2, pp. 261–270, 2020, [Online]. Available: <http://ejournal-s1.undip.ac.id/index.php/gaussian>
- [3] K. S. Moon and H. Kim, "Performance of deep learning in prediction of stock market volatility," *Econ Comput Econ Cybern Stud Res*, vol. 53, no. 2, pp. 77–92, 2019, doi: 10.24818/18423264/53.2.19.05.
- [4] T. Trimono, I. Gede Susrama, K. Maulida H, and M. Idhom, "Model ARIMA-ARCH/GARCH dan Ensemble ARIMA-ARCH/GARCH untuk Prediksi Kerugian pada Harga Komoditas Pertanian," *Seminar Nasional Sains Data*, vol. 2021.
- [5] M. Nasrudin, E. Setyowati, and S. S. May Wara, "Application of VAR-GARCH for Modeling the Causal Relationship of Stock Prices in the Mining Sub-sector," *Jurnal Varian*, vol. 8, no. 1, pp. 89–96, Nov. 2024, doi: 10.30812/varian.v8i1.4239.
- [6] M. Idhom, A. Fauzi, T. Trimono, and P. Riyantoko, "Time Series Regression: Prediction of Electricity Consumption Based on Number of Consumers at National Electricity Supply Company," *TEM Journal*, vol. 12, no. 3, pp. 1575–1581, Aug. 2023, doi: 10.18421/TEM123-39.
- [7] W. Lu, J. Li, Y. Li, A. Sun, and J. Wang, "A CNN-LSTM-based model to forecast stock prices," *Complexity*, vol. 2020, 2020, doi: 10.1155/2020/6622927.
- [8] N. Gupta and A. S. Jalal, "Integration of textual cues for fine-grained image captioning using deep CNN and LSTM," *Neural Comput Appl*, vol. 32, no. 24, pp. 17899–17908, Dec. 2020, doi: 10.1007/s00521-019-04515-z.
- [9] M. Maliki, Cholissodin. Imam, and N. Yudistira, "Prediksi Pergerakan Harga Cryptocurrency Bitcoin terhadap Mata Uang Ru[ia]h menggunakan Algoritme LSTM," *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, vol. 6, no. Vol. 6, No.7, p. 32593268, Jul. 2022.
- [10] H. Y. Kim and C. H. Won, "Forecasting the volatility of stock price index: A hybrid model integrating LSTM with multiple GARCH-type models," *Expert Syst Appl*, vol. 103, pp. 25–37, Aug. 2020, doi: 10.1016/j.eswa.2018.03.002.
- [11] A. Arfan and L. ETP, "Perbandingan Algoritma Long Short-Term Memory dengan SVR Pada Prediksi Harga Saham di Indonesia," *PETIR*, vol. 13, no. 1, pp. 33–43, Mar. 2020, doi: 10.33322/petir.v13i1.858.
- [12] D. A. Prasetya, A. P. Sari, P. A. Riyantoko, and T. M. Fahrudin, "The Effect of Information Quality and Service Quality on User Satisfaction of the Government of Kabupaten Malang," *TIERS Information Technology Journal*, vol. 4, no. 1, pp. 32–42, Jun. 2023, doi: 10.38043/tiers.v4i1.4328.
- [13] B. S. Kim and T. G. Kim, "Cooperation of simulation and data model for performance analysis of complex systems," *International Journal of Simulation Modelling*, vol. 18, no. 4, pp. 608–619, Dec. 2019, doi: 10.2507/IJSIMM18(4)491.
- [14] M. L. Brocardo, I. Traore, I. Woungang, and M. S. Obaidat, "Authorship verification using deep belief network systems," *International Journal of Communication Systems*, vol. 30, no. 12, Aug. 2019, doi: 10.1002/dac.3259.
- [15] P. Aji Riyantoko, T. Maulana Fahrudin, K. Maulida Hindrayani, and E. Maya Safitri, "ANALISIS PREDIKSI HARGA SAHAM SEKTOR PERBANKAN MENGGUNAKAN



- ALGORITMA LONG-SHORT TERMS MEMORY (LSTM),” *Seminar Nasional Informatika*, vol. 2020.
- [16] Z. Jin, Y. Yang, and Y. Liu, “Stock closing price prediction based on sentiment analysis and LSTM,” *Neural Comput Appl*, vol. 32, no. 13, pp. 9713–9729, Jul. 2020, doi: 10.1007/s00521-019-04504-2.
- [17] I. Athallah Taufik and A. Muhaimin, “Prediction of the Islamic Stock Price Index and Risk of Loss Using the LSTM (Long Short-Term Memory) and VaR (Value at Risk) Methods,” vol. 4, no. 1, pp. 11–22, doi: 10.3390/xxxxx.
- [18] A. Yadav, C. K. Jha, and A. Sharan, “Optimizing LSTM for time series prediction in Indian stock market,” in *Procedia Computer Science*, Elsevier B.V., 2020, pp. 2091–2100. doi: 10.1016/j.procs.2020.03.257.
- [19] S. Borovkova and I. Tsiamas, “An ensemble of LSTM neural networks for high-frequency stock market classification,” *J Forecast*, vol. 38, no. 6, pp. 600–619, Sep. 2019, doi: 10.1002/for.2585.
- [20] R. Faza Inaku and J. C. Chandra, “Implementasi Data Mining dalam Prediksi Harga Saham Menggunakan Metode Long Short Term Memory (LSTM),” *Jurnal TICOM: Technology of Information and Communication*, vol. 12, no. 1, 2023.
- [21] N. C. Petersen, F. Rodrigues, and F. Camara Pereira, “Multi-output Bus Travel Time Prediction with Convolutional LSTM Neural Network.”
- [22] V. D. Ta, C. M. Liu, and D. A. Tadesse, “Portfolio optimization-based stock prediction using long-short term memory network in quantitative trading,” *Applied Sciences (Switzerland)*, vol. 10, no. 2, Jan. 2020, doi: 10.3390/app10020437.
- [23] C. I. Garcia, F. Grasso, A. Luchetta, M. C. Piccirilli, L. Paolucci, and G. Talluri, “A comparison of power quality disturbance detection and classification methods using CNN, LSTM and CNN-LSTM,” *Applied Sciences (Switzerland)*, vol. 10, no. 19, pp. 1–22, Oct. 2020, doi: 10.3390/app10196755.
- [24] P. Aji Riyantoko and F. Agista, “Model ARMA-GARCH dan Ensemble ARMA-GARCH untuk Prediksi Value-at-Risk pada Portofolio Saham,” *Seminar Nasional Sains Data*, vol. 2022.
- [25] A. Arimond SDGLabsai Sweden *et al.*, “NEURAL NETWORKS AND VALUE AT RISK IN ASSET MANAGEMENT A PREPRINT Acknowledgments: We are grateful for comments from Neural Networks and Value at Risk in Asset Management A PREPRINT Neural Networks and Value at Risk in Asset Management A PREPRINT.”
- [26] Trimono and F. Agista, “Model ARMA-GARCH Prediksi Value-at-Risk pada Saham”.
- [27] R. Andespa and D. I. Asih Maruddani, “EXPECTED SHORTFALL DENGAN EKSPANSI CORNISH-FISHER UNTUK ANALISIS RISIKO INVESTASI SEBELUM DAN SESUDAH PANDEMI COVID-19 DILENGKAPI GUI R,” vol. 11, no. 2, pp. 173–182, 2022, [Online]. Available: <https://ejournal3.undip.ac.id/index.php/gaussian/>
- [28] M. R. Firmansyah, R. Ilyas, and F. Kasyidi, “Klasifikasi Klimat Ilmiah Menggunakan Reccurent Neural Network,” 2020.
- [29] D. A. Prasetya, A. Sanusi, G. Chandrarin, E. Roikhah, I. Mujahidin, and R. Arifuddin, “Small and Medium Enterprises Problem and Potential Solutions for Waste Management,” *Journal of Southwest Jiaotong University*, vol. 54, no. 6, 2019, doi: 10.35741/issn.0258-2724.54.6.21.

